

UNED IA 2026/27

FUNDAMENTOS DE MODELADO ESTADÍSTICO DE DATOS

Código 71032021

DE LOS DATOS A UNA DECISIÓN QUE SE PUEDA JUSTIFICAR

Aprenderás a explicar y predecir resultados, medir el error y distinguir un modelo que ha aprendido de otro que solo ha memorizado.


Manual completo desde cero · 9 temas · R · 54 ejercicios · simulacro

Antes de empezar

LA IDEA CENTRAL

Tenemos datos conocidos. Elegimos una respuesta que queremos explicar, seleccionamos predictores, ajustamos un modelo y comprobamos si funciona con datos que no utilizó para aprender.

Un modelo útil no solo encaja: funciona con casos nuevos.



Separar entrenamiento y evaluación evita confundir memoria con aprendizaje.

Mapa oficial convertido en preguntas sencillas

Tema	Contenido oficial	Pregunta humana
1	Simulación estadística	¿Cómo genero resultados que siguen un modelo de probabilidad?
2	Índices de riesgo	¿Cuánto cambia un riesgo entre dos grupos?
3	Técnicas diagnósticas	¿Cómo sé si una prueba distingue bien positivos y negativos?
4	Regresión lineal	¿Cómo explico una cantidad mediante varios predictores?
5	Ridge, LASSO, PCR y PLS	¿Cómo controlo modelos inestables o con muchos predictores?
6	Análisis discriminante	¿Cómo clasifico usando distribuciones por grupos?
7	Regresión logística	¿Cómo modelo la probabilidad de una categoría?
8	Modelos lineales generalizados	¿Cómo adapto el modelo a conteos y otras respuestas?
9	Evaluación y selección	¿Qué modelo funcionará mejor con datos nuevos?

Cómo se evalúa oficialmente

Elemento	Dato de la guía pública 2026/27
Asignatura	2.º curso · semestre 1 · obligatoria · 6 ECTS · 150 horas
Examen	120 minutos · 6 verdadero/falso justificados + 1 desarrollo
Material	Todo tipo de material escrito y calculadora programable
Peso del examen	40 %
Foro o tarea alternativa	10 % · no obligatorio; si no se hace, vale 0
Trabajo teórico	10 % · no obligatorio; si no se hace, vale 0
Práctica 1	20 % · obligatoria y debe aprobarse
Práctica 2	20 % · obligatoria y debe aprobarse

FÓRMULA DE LA NOTA

$NF = 0,4 \cdot Ex + 0,2 \cdot P1 + 0,2 \cdot P2 + 0,1 \cdot F + 0,1 \cdot T$. Aprobar ambas prácticas es condición necesaria para aprobar la asignatura.

Cómo se puntúan las seis afirmaciones

Según la guía, una respuesta equivocada vale 0; una respuesta acertada sin justificación completa vale 0,1; una respuesta acertada y demostrada o refutada con un contraejemplo puede alcanzar 1,5. Por eso entrenaremos siempre **decisión + razón + prueba o contraejemplo**.

FECHAS APROXIMADAS PUBLICADAS

Foro/tarea alternativa: 13 de enero. Trabajo teórico: 13 de enero. Práctica 1: 13 de diciembre. Práctica 2: 13 de enero. Confirma siempre las fechas efectivas en el curso virtual.

Puente de Estadística desde cero

POR QUÉ EXISTE ESTE PUENTE

La guía presupone Cálculo, Álgebra y Fundamentos de Estadística. Como tú cursarás Estadística en el segundo cuatrimestre, aquí reconstruimos lo imprescindible antes de utilizarlo.

1. Filas, columnas y preguntas

persona	horas_estudio	nota	aprobó
Ana	2	5,5	sí
Luis	5	8,0	sí
Marta	1	3,5	no
Pablo	4	7,0	sí

Cada **fila** es una observación. Cada **columna** es una variable. Si queremos predecir nota, nota es la **respuesta Y** y horas_estudio puede ser un **predictor X**. Si queremos predecir aprobó, la respuesta es cualitativa y el problema es de clasificación.

2. Población, muestra y parámetro

La **población** es el conjunto que nos interesa. Una **muestra** es la parte observada. Un **parámetro** es una característica desconocida de la población; un **estadístico** se calcula con la muestra para estimarlo.

MEDIA Y VARIANZA CON 2, 4 Y 6

Media: $(2+4+6)/3 = 4$. Es el centro aritmético.

Desviaciones respecto de la media: -2, 0 y 2.

Cuadrados: 4, 0 y 4. Varianza muestral: $(4+0+4)/(3-1)=4$.

Desviación típica: raíz de 4 = 2. Vuelve a las unidades originales.

Probabilidad sin símbolos misteriosos

Concepto	En lenguaje corriente	Ejemplo
Suceso	Resultado o conjunto de resultados	sacar un número par
$P(A)$	probabilidad de A	3 pares de 6: 3/6
Condicionada $P(A B)$	probabilidad de A sabiendo B	aprobar sabiendo que estudió
Independencia	saber B no cambia $P(A)$	dos lanzamientos separados
Variable aleatoria	número producido por el azar	número de llamadas
Esperanza $E[X]$	promedio a largo plazo	media teórica

Modelos básicos

Modelo	Qué representa	Parámetros	Ejemplo
Bernoulli	un sí/no	p	una compra
Binomial	n intentos sí/no	n, p	compras en 20 visitas
Normal	medida continua alrededor de una media	μ, σ	errores de medida
Poisson	conteos en intervalo	λ	llamadas por hora

NO CONFUNDAS

Un modelo de probabilidad no afirma qué ocurrirá en un caso concreto. Describe frecuencias y variabilidad cuando el mecanismo se repite.

Covarianza y correlación

La covarianza indica si dos variables tienden a moverse juntas. La correlación la normaliza entre -1 y 1. Correlación positiva significa que suelen crecer juntas; negativa, que una suele bajar cuando la otra sube; cero significa ausencia de relación lineal, no independencia garantizada.

Estimación, incertidumbre y contraste

Estimación puntual e intervalo

Una estimación puntual da un número, por ejemplo media = 4. Un intervalo de confianza añade incertidumbre, por ejemplo [3,2; 4,8]. Un intervalo del 95 % se construye mediante un procedimiento que, repetido muchas veces, cubriría el parámetro verdadero aproximadamente en el 95 % de las muestras.

FRASE PELIGROSA

No digas: “hay un 95 % de probabilidad de que este parámetro fijo esté dentro del intervalo” en la interpretación frecuentista habitual. La aleatoriedad está en el procedimiento y en la muestra.

Hipótesis y valor p

H0 es una afirmación de referencia. El valor p mide lo incompatibles que son los datos con H0: es la probabilidad, suponiendo H0, de obtener un resultado tan extremo o más que el observado. No es la probabilidad de que H0 sea cierta.

Error	Qué ocurre
Tipo I	rechazamos H0 siendo verdadera; falso positivo
Tipo II	no rechazamos H0 siendo falsa; falso negativo

Álgebra matricial mínima

Una matriz es una tabla de números. En regresión, X guarda predictores por filas y columnas; y guarda las respuestas; β guarda los coeficientes. La expresión $y = X\beta + \varepsilon$ resume muchas ecuaciones a la vez. Transponer X, escrito X^T , intercambia filas y columnas.

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} \quad y = X\beta + \text{error}$$

R desde cero

R es el programa estadístico indicado por la guía. El símbolo `<-` asigna un valor. Una función recibe argumentos entre paréntesis. El símbolo `$` selecciona una columna de una tabla.

```
x <- c(2, 4, 6)           # vector
mean(x)                  # media: 4
sd(x)                    # desviación típica muestral: 2
datos <- data.frame(horas=c(1,2,4,5), nota=c(3.5,5.5,7,8))
modelo <- lm(nota ~ horas, data=datos)
summary(modelo)
predict(modelo, newdata=data.frame(horas=3))
```

Símbolo	Lectura
<code>c(...)</code>	combina valores en un vector
<code>data.frame</code>	crea una tabla
<code>y ~ x1 + x2</code>	modela y mediante x1 y x2
<code>lm</code>	regresión lineal
<code>glm(..., family=binomial)</code>	regresión logística
<code>set.seed(7)</code>	permite repetir una simulación

REGLA DE TRABAJO

Antes de interpretar una salida, escribe: qué representa cada fila, cuál es la respuesta, cuáles son los predictores y qué pregunta concreta intentas contestar.

TEMA 1

Simulación estadística de modelos de probabilidad

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo puedo fabricar datos que sigan un mecanismo probabilístico conocido?

AL TERMINAR PODRÁS

Reconocer variables aleatorias, simular distribuciones, transformar resultados y aproximar probabilidades mediante Monte Carlo.

1.1 Simular no es inventar sin reglas

Simular significa usar un generador aleatorio y una regla matemática para producir observaciones con una distribución elegida. Sirve para comprender modelos, comprobar algoritmos y estudiar situaciones difíciles de calcular exactamente.

```
set.seed(21)
u <- runif(10000)           # Uniforme entre 0 y 1
x <- rbinom(10000, 1, 0.30) # 10000 Bernoulli con p=0,30
mean(x)                     # se aproxima a 0,30
```

MONTE CARLO: PROBABILIDAD DE AL MENOS UN 6 EN DOS DADOS

Repetimos muchas veces dos lanzamientos.

En cada repetición guardamos 1 si aparece algún 6 y 0 en caso contrario.

La media de ceros y unos aproxima la probabilidad.

La probabilidad exacta es $1 - (5/6)^2 = 11/36 \approx 0,306$. La simulación debe acercarse, no coincidir exactamente.

```
set.seed(4)
d1 <- sample(1:6, 100000, replace=TRUE)
d2 <- sample(1:6, 100000, replace=TRUE)
mean(d1==6 | d2==6)
```

1.2 Transformar variables

Si X es una variable aleatoria y definimos $Y=a+bX$, entonces $E[Y]=a+bE[X]$ y $\text{Var}(Y)=b^2\text{Var}(X)$. Sumar una constante mueve el centro, pero no cambia la dispersión; multiplicar por b cambia la desviación típica por $|b|$.

CAMBIAR GRADOS CELSIUS A FAHRENHEIT

$F = 32 + 1,8 \cdot C$.

Si $E[C]=20$, entonces $E[F]=32+1,8 \cdot 20=68$.

Si $\text{sd}(C)=3$, entonces $\text{sd}(F)=1,8 \cdot 3=5,4$. El 32 no añade variabilidad.

1.3 Dos variables juntas

Para sumar variables: $E[X+Y]=E[X]+E[Y]$. Para la varianza: $\text{Var}(X+Y)=\text{Var}(X)+\text{Var}(Y)+2\text{Cov}(X,Y)$. Solo si son independientes la covarianza es cero y podemos sumar directamente las varianzas.

Ahora tú

HAZLO SIN MIRAR

1. ¿Qué hace `set.seed`?
2. Si X es $\text{Bernoulli}(p)$, ¿qué estima `mean(X)`?
3. $E[X]=5$. Calcula $E[3+2X]$.
4. $\text{Var}(X)=4$. Calcula $\text{Var}(3+2X)$.
5. ¿Una simulación de 100 repeticiones debe dar el valor exacto?

CORRECCIÓN EXPLICADA

1. Fija el estado del generador para repetir los mismos resultados.
2. p .
3. $3+2\cdot 5=13$.
4. $2^2\cdot 4=16$.
5. No; produce una aproximación aleatoria que mejora normalmente al aumentar repeticiones.

TEMA 2

Índices de riesgo

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo comparo la frecuencia de un resultado entre un grupo expuesto y otro no expuesto?

AL TERMINAR PODRÁS

Construir una tabla 2x2 y calcular diferencia de riesgos, riesgo relativo y odds ratio sin confundirlos.

	Resultado +	Resultado -	Total
Expuesto +	a = 30	b = 70	100
Expuesto -	c = 10	d = 90	100
Total	40	160	200

2.1 Primero calcula los dos riesgos

Riesgo expuestos = $a/(a+b)=30/100=0,30$. Riesgo no expuestos = $c/(c+d)=10/100=0,10$. Cada riesgo usa como denominador el total de su propio grupo.

Índice	Fórmula	Resultado	Interpretación
Diferencia de riesgos	$R1-R0$	$0,30-0,10=0,20$	20 puntos porcentuales más
Riesgo relativo	$R1/R0$	$0,30/0,10=3$	el riesgo es 3 veces
Odds ratio	$(a/b)/(c/d)=ad/bc$	$2700/700=3,86$	las odds son 3,86 veces

RIESGO NO ES ODDS

Con riesgo 0,30, las odds son $0,30/0,70=0,429$. Solo cuando el resultado es raro, OR y RR suelen parecerse. No interpretes $OR=3,86$ como "3,86 veces el riesgo".

2.2 Incertidumbre

Los índices calculados en una muestra varían. Un intervalo de confianza muestra valores compatibles con los datos. Para RR y OR, el valor de ausencia de asociación es 1; para diferencia de riesgos es 0. Si un intervalo incluye el valor nulo, los datos no descartan ausencia de asociación al nivel utilizado.

Ahora tú

HAZLO SIN MIRAR

1. En la tabla, ¿cuál es el riesgo expuesto?
2. ¿Cuál es la diferencia de riesgos?
3. ¿Qué significa $RR=1$?
4. ¿Qué significa $DR=0$?
5. ¿Por qué OR y RR no son sinónimos?

CORRECCIÓN EXPLICADA

1. $30/(30+70)=0,30$.
2. 0,20 o 20 puntos porcentuales.
3. Igual riesgo en ambos grupos.
4. Ninguna diferencia absoluta de riesgo.
5. OR compara odds; RR compara probabilidades. Coinciden solo en casos especiales.

TEMA 3

Técnicas diagnósticas

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo evalúo una prueba que intenta separar positivos y negativos?

AL TERMINAR PODRÁS

Calcular sensibilidad, especificidad, valores predictivos y razones de verosimilitud, y entender umbral, ROC y AUC.

	Real +	Real -
Test +	VP=80	FP=20
Test -	FN=20	VN=180

Medida	Fórmula	Resultado	Pregunta
Sensibilidad	$VP/(VP+FN)$	$80/100=0,80$	de los reales +, ¿cuántos detecto?
Especificidad	$VN/(VN+FP)$	$180/200=0,90$	de los reales -, ¿cuántos descarto?
VPP	$VP/(VP+FP)$	$80/100=0,80$	si test +, ¿qué probabilidad de real +?
VPN	$VN/(VN+FN)$	$180/200=0,90$	si test -, ¿qué probabilidad de real -?

QUÉ DEPENDE DE LA PREVALENCIA

Sensibilidad y especificidad describen el comportamiento condicionado al estado real. VPP y VPN cambian mucho cuando cambia la frecuencia del resultado en la población.


3.1 Razones de verosimilitud

$LR+ = \text{sensibilidad}/(1-\text{especificidad})=0,80/0,10=8$. Un positivo es ocho veces más probable en una persona realmente positiva que en una negativa.

$LR-=(1-\text{sensibilidad})/\text{especificidad}=0,20/0,90\approx0,22$. Un buen $LR+$ es grande; un buen $LR-$ se acerca a 0.

Umbral bajo


Umbral alto



Bajar el umbral detecta más positivos, pero puede crear más falsos positivos.

3.2 Curva ROC

Cada umbral produce una sensibilidad y una tasa de falsos positivos $1 - \text{especificidad}$. La ROC reúne todos esos pares. $\text{AUC} = 0,5$ equivale a discriminación aleatoria; 1 representa separación perfecta. AUC no elige por sí sola el umbral ni mide calibración.



Ahora tú

HAZLO SIN MIRAR

1. Calcula sensibilidad.
2. Calcula especificidad.
3. ¿Qué cambia al bajar el umbral?
4. ¿ $\text{AUC} = 0,5$ es perfecta?
5. ¿VPP es independiente de prevalencia?

CORRECCIÓN EXPLICADA

1. $80 / (80 + 20) = 0,80$.
2. $180 / (180 + 20) = 0,90$.
3. Suele aumentar sensibilidad y también falsos positivos.
4. No, equivale aproximadamente al azar.
5. No; depende de la prevalencia y del rendimiento de la prueba.

TEMA 4


Regresión lineal

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo explico o predigo una cantidad mediante uno o varios predictores?

AL TERMINAR PODRÁS

Interpretar coeficientes, predicciones, residuos, supuestos e incertidumbre en regresión lineal múltiple.



4.1 El modelo

Para una persona i : $y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i$. β_0 es el valor esperado cuando todos los predictores valen 0. β_j es el cambio esperado en Y por una unidad adicional de X_j , **manteniendo constantes los demás predictores**. ε representa lo que el modelo no explica.

MODELO DE NOTA

Ajustamos $\text{nota} = 2 + 0,8 \cdot \text{horas} + 0,5 \cdot \text{asistencia}$.

Si horas aumenta en 1 y asistencia no cambia, la nota esperada aumenta 0,8.

Para horas=4 y asistencia=1: predicción= $2 + 0,8 \cdot 4 + 0,5 = 5,7$.

Si la nota observada fue 6,2, el residuo es observado-predicho= $6,2 - 5,7 = 0,5$.

4.2 Mínimos cuadrados

El ajuste elige coeficientes que minimizan la suma de residuos al cuadrado, $SSE = \sum (y_i - \hat{y}_i)^2$. En notación matricial, si $X^T X$ es invertible, $\beta = (X^T X)^{-1} X^T y$. La fórmula importa, pero más aún comprender qué está optimizando.

4.3 Supuestos y diagnóstico

Supuesto	Qué mirar	Si falla
Linealidad	residuos sin curva	transformar o cambiar modelo
Independencia	diseño y orden temporal	modelar dependencia
Varianza constante	dispersión similar	errores robustos/transformación
Normalidad de errores	QQ-plot para inferencia	cuidado con intervalos y pruebas
Sin colinealidad extrema	VIF/relaciones entre X	regularizar o revisar variables

```
m <- lm(nota ~ horas + asistencia, data=datos)
coef(m); summary(m)
plot(m) # gráficos diagnósticos
predict(m, nuevos, interval="prediction")
```

INTERVALOS DIFERENTES

El intervalo de confianza estima la media esperada. El intervalo de predicción cubre una observación nueva y es más ancho porque añade variabilidad individual.

Ahora tú

HAZLO SIN MIRAR

1. ¿Qué minimiza mínimos cuadrados?
2. Interpreta $\beta_1=0,8$.
3. Predice con horas=2, asistencia=1.
4. Observado 5 y predicho 4,6: residuo.
5. ¿Un R^2 alto demuestra causalidad?

CORRECCIÓN EXPLICADA

1. La suma de residuos al cuadrado.
2. Una unidad más de horas se asocia con +0,8 en nota esperada, manteniendo lo demás constante.
3. $2+0,8\cdot 2+0,5=4,1$.
4. $5-4,6=0,4$.
5. No. Describe ajuste en esos datos; no establece diseño causal ni generalización.

TEMA 5

Variantes de la regresión lineal

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Qué hago cuando hay muchos predictores, están muy relacionados o el modelo varía demasiado?

AL TERMINAR PODRÁS

Distinguir ridge, LASSO, PCR y PLS y relacionarlos con sesgo, varianza y validación.

5.1 El problema: inestabilidad

Si dos predictores cuentan casi lo mismo, pequeños cambios en los datos pueden cambiar mucho sus coeficientes. Si hay demasiados predictores, el modelo puede memorizar ruido. La regularización acepta algo de sesgo para reducir varianza y mejorar predicción nueva.

Método	Qué hace	Efecto típico
Ridge	añade $\lambda \sum \beta_j^2$	encoge coeficientes; rara vez los hace 0
LASSO	añade $\lambda \sum \beta_j $	puede hacer coeficientes exactamente 0
PCR	regresión sobre componentes de X	reduce dimensión sin usar Y al construir componentes
PLS	componentes relacionados con X e Y	reduce dimensión usando información de Y

ANTES DE PENALIZAR

Estandariza los predictores para que la penalización no dependa de sus unidades. El intercepto suele quedar sin penalizar. λ se selecciona mediante validación, no mirando el conjunto de prueba final.

QUÉ OCURRE AL AUMENTAR λ

Con $\lambda=0$ recuperamos el ajuste sin penalización.

Al aumentar λ , los coeficientes se acercan a 0.

Ridge reparte peso entre predictores correlacionados; LASSO puede escoger unos y anular otros.

Un λ excesivo subajusta: simplifica tanto que pierde señal.

```
# Esquema conceptual con glmnet
x <- model.matrix(y ~ ., datos)[-1]
ajuste <- glmnet::cv.glmnet(x, datos$y, alpha=0) # ridge
ajuste_lasso <- glmnet::cv.glmnet(x, datos$y, alpha=1)
```

Ahora tú

HAZLO SIN MIRAR

1. ¿Ridge selecciona variables haciendo muchos coeficientes 0?
2. ¿Qué método sí puede hacerlo?
3. ¿Por qué estandarizar?
4. ¿PCR usa Y para crear componentes?
5. ¿Cómo elegir λ ?

CORRECCIÓN EXPLICADA

1. No; normalmente los encoge sin anularlos.
2. LASSO.
3. Para que las unidades no determinen cuánto se penaliza cada predictor.
4. No. PLS sí incorpora Y.
5. Con validación, reservando el test final.

TEMA 6

Análisis discriminante

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo clasifico una observación comparando la distribución de sus predictores en cada grupo?

AL TERMINAR PODRÁS

Entender la regla de Bayes, las diferencias entre LDA y QDA y el papel de medias, covarianzas y probabilidades previas.

6.1 La idea

Para cada clase k estimamos cómo se distribuyen los predictores y su probabilidad previa π_k . Para un nuevo x calculamos qué clase tiene mayor probabilidad posterior $P(\text{clase}=k|x)$. Esto aplica la regla de Bayes.

Modelo	Supuesto sobre covarianza	Frontera	Necesita
LDA	misma matriz para todas las clases	lineal	menos datos
QDA	una matriz por clase	cuadrática	más datos

CLASIFICAR POR UNA MEDIDA

Clase A: media 4; clase B: media 8; ambas con igual dispersión y misma probabilidad previa.

Una observación $x=4,5$ está mucho más cerca de la media de A.

LDA asignará normalmente A. Si B fuese muchísimo más frecuente, la probabilidad previa podría desplazar la frontera.

```
library(MASS)
m_lda <- lda(clase ~ x1 + x2, data=entrenamiento)
pred <- predict(m_lda, newdata=prueba)
pred$class      # clase elegida
pred$posterior  # probabilidades posteriores
```

NO CONFUNDAS

LDA significa análisis discriminante lineal. No es lo mismo que una regresión lineal aplicada a etiquetas 0/1. Su modelo probabilístico y sus supuestos son distintos.

Ahora tú

HAZLO SIN MIRAR

1. ¿Qué elige la regla de clasificación?
2. ¿LDA usa una covarianza por clase?
3. ¿QDA tiene frontera lineal?
4. ¿Qué papel tiene π_k ?
5. ¿QDA suele necesitar más datos?

CORRECCIÓN EXPLICADA

1. La clase con mayor probabilidad posterior o menor pérdida definida.
2. No; comparte una matriz de covarianzas.
3. No; normalmente es cuadrática.
4. Representa la probabilidad previa de cada clase.
5. Sí, porque estima más parámetros.

TEMA 7


Regresión logística

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo modelo directamente la probabilidad de que ocurra un resultado sí/no?

AL TERMINAR PODRÁS

Pasar de probabilidad a odds y logit, interpretar coeficientes, obtener probabilidades y elegir un umbral conscientemente.



7.1 Probabilidad, odds y logit

Cantidad	Fórmula	Con $p=0,80$
Probabilidad	p	0,80
Odds	$p/(1-p)$	$0,8/0,2=4$
Logit	$\log[p/(1-p)]$	$\log(4)=1,386$

El modelo es $\text{logit}(p)=\beta_0+\beta_1x_1+\dots+\beta_px_p$. Al aplicar la función logística obtenemos $p=1/(1+e^{-\eta})$, siempre entre 0 y 1.

INTERPRETAR UN COEFICIENTE

Supón $\beta_{\text{horas}}=0,693$.

Una hora más multiplica las odds por $\exp(0,693)\approx 2$, manteniendo los demás predictores constantes.

No significa que la probabilidad se duplique: el cambio de probabilidad depende del punto de partida.

7.2 Ajuste e inferencia

Los coeficientes se estiman por máxima verosimilitud. No hay una fórmula cerrada como en mínimos cuadrados; se usa un algoritmo iterativo. La deviance mide falta de ajuste relativa y permite comparar modelos anidados bajo condiciones adecuadas.

```
m <- glm(aprueba ~ horas + asistencia, data=datos, family=binomial)
summary(m)
p <- predict(m, nuevos, type="response")
clase <- ifelse(p >= 0.5, "sí", "no")
exp(coef(m)) # odds ratios por unidad
```

EL UMBRAL NO VIENE ESCRITO POR LA NATURALEZA

0,5 es una elección, no una ley. Si perder un positivo es muy grave, puede bajarse el umbral; después deben medirse sensibilidad, especificidad y costes.

Ahora tú

HAZLO SIN MIRAR

1. Con $p=0,75$, calcula odds.
2. Con $\text{odds}=4$, calcula p .
3. Interpreta $\exp(\beta)=1$.
4. ¿El coeficiente logístico es un cambio directo de probabilidad?
5. ¿Por qué el ajuste es iterativo?

CORRECCIÓN EXPLICADA

1. $0,75/0,25=3$.
2. $4/(1+4)=0,80$.
3. El predictor no cambia las odds por unidad, manteniendo los demás constantes.
4. No; es cambio en log-odds. $\exp(\beta)$ es factor de odds.
5. Porque la máxima verosimilitud logística no tiene la misma solución cerrada que mínimos cuadrados.

TEMA 8

Modelos lineales generalizados

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo conservo una estructura lineal cuando la respuesta no es normal?

AL TERMINAR PODRÁS

Reconocer las tres piezas de un GLM e interpretar el modelo de Poisson para conteos.

8.1 Las tres piezas

Pieza	Qué es	Ejemplo Poisson
Componente aleatoria	distribución de Y	Poisson
Predictor lineal	$\eta = X\beta$	$\beta_0 + \beta_1 x$
Función de enlace	conecta $E[Y]$ con η	$\log(\mu) = \eta$

En Poisson, $\mu = E[Y|X] = \exp(\eta)$, por lo que la media siempre es positiva. $\exp(\beta_j)$ es el factor multiplicativo de la tasa esperada por una unidad de X_j , manteniendo lo demás constante.

LLAMADAS POR HORA

Modelo: $\log(\mu) = 1 + 0,20 \cdot \text{publicidad}$.

Sin publicidad: $\mu = \exp(1) = 2,72$ llamadas.

Una unidad adicional multiplica la media por $\exp(0,20) = 1,22$: aproximadamente un 22 % más.

Con publicidad=2: $\mu = \exp(1,4) = 4,06$.

8.2 Exposición y offset

No es lo mismo contar 20 incidentes en 10 horas que en 100. Si cada observación tiene distinta exposición t , se modela la tasa añadiendo $\text{offset}(\log t)$. Su coeficiente queda fijado en 1.

8.3 Sobredispersión

Poisson supone $\text{Var}(Y|X) = E[Y|X]$. Si la varianza es mucho mayor, hay sobredispersión: los errores estándar pueden quedar demasiado pequeños. Deben revisarse el modelo, la dependencia y alternativas como quasi-Poisson o binomial negativa.

```
m <- glm(llamadas ~ publicidad + offset(log(horas)),
        family=poisson, data=datos)
exp(coef(m))
```

Ahora tú

HAZLO SIN MIRAR

1. Nombra las tres piezas de un GLM.
2. ¿Por qué usar enlace log en Poisson?
3. Interpreta $\exp(\beta)=1,5$.
4. ¿Qué corrige un offset?
5. ¿Qué es sobredispersión?

CORRECCIÓN EXPLICADA

1. Distribución de Y, predictor lineal y enlace.
2. Convierte cualquier η en una media positiva y modela efectos multiplicativos.
3. La tasa esperada se multiplica por 1,5 por unidad, manteniendo lo demás constante.
4. Diferentes tiempos o cantidades de exposición.
5. Varianza observada/condicional mayor de lo que permite Poisson.

TEMA 9

Evaluación y selección de modelos

LA PREGUNTA QUE APRENDERÁS A CONTESTAR

¿Cómo elijo un modelo que funcione con datos nuevos y no solo con los usados para ajustarlo?

AL TERMINAR PODRÁS

Separar datos, validar, elegir métricas, detectar sobreajuste y controlar multicolinealidad.

9.1 Entrenamiento, validación y prueba

Entrenamiento ajusta parámetros. Validación elige hiperparámetros y modelos. Prueba estima una sola vez el rendimiento final. Si usamos el test repetidamente para decidir, deja de ser una evaluación independiente.

Problema	Señal	Respuesta
Subajuste	mal en train y test	modelo más flexible/mejores variables
Sobreajuste	muy bien en train, mal en test	regularizar, validar, más datos
Fuga de datos	resultado irrealmente bueno	hacer todo el preprocesado dentro del entrenamiento

9.2 Métricas

Tarea	Métrica	Qué resume
Regresión	MSE/RMSE	penaliza mucho errores grandes
Regresión	MAE	error absoluto típico; robusto frente a extremos
Clasificación	accuracy	proporción total correcta
Clasificación	sensibilidad/especificidad	rendimiento por clase real
Probabilidad	log-loss	calidad de probabilidades; castiga confianza errónea
Ranking	AUC ROC	capacidad de ordenar positivos sobre negativos

CLASE DESEQUILIBRADA

Con 1 % de positivos, predecir siempre negativo logra 99 % de accuracy y no detecta ninguno. Elige métricas según la decisión y el coste de errores.

9.3 Validación cruzada

En k-fold dividimos entrenamiento en k partes. Ajustamos k veces: cada vez una parte valida y las otras k-1 entrenan. Promediamos la métrica. Todo paso aprendido de los datos -escalado, imputación, selección- debe repetirse dentro de cada pliegue.

9.4 Selección y multicolinealidad

AIC y BIC equilibran ajuste y complejidad bajo supuestos; menor suele preferirse entre modelos comparables. VIF mide cuánto se infla la varianza de un coeficiente por relaciones lineales entre predictores. Colinealidad puede volver inestable la interpretación aunque la predicción sea razonable.

Ahora tú

HAZLO SIN MIRAR

1. ¿Para qué sirve el test?
2. ¿Debe elegirse λ con el test final?
3. ¿Accuracy basta con 1 % de positivos?
4. ¿Qué evita fuga en validación?
5. ¿VIF alto demuestra que el modelo predice mal?

CORRECCIÓN EXPLICADA

1. Para estimar rendimiento final sobre datos no usados en decisiones.
2. No; se elige con validación.
3. No; puede ocultar que no se detecta ningún positivo.
4. Ajustar preprocesado y selección dentro de cada pliegue.
5. No necesariamente; señala inestabilidad de coeficientes por colinealidad.

Banco de 54 ejercicios progresivos

Haz seis por tema. Escribe siempre fórmula, sustitución, resultado e interpretación. En verdadero/falso, añade demostración o contraejemplo.

N.º	Tema	Ejercicio
1	Simulación	Diferencia entre simular e inventar.
2	Simulación	¿Qué garantiza set.seed?
3	Simulación	Estima $P(\text{cara})$ con 10000 Bernoulli.
4	Simulación	$E[2+3X]$ si $E[X]=4$.
5	Simulación	$\text{Var}(2+3X)$ si $\text{Var}(X)=2$.
6	Simulación	$\text{Var}(X+Y)$ sin independencia.
7	Riesgo	Riesgos de tabla $a=20, b=80, c=10, d=90$.
8	Riesgo	Diferencia de riesgos.
9	Riesgo	Riesgo relativo.
10	Riesgo	Odds ratio.
11	Riesgo	Valor nulo de RR y DR.
12	Riesgo	Explica por qué OR no es RR.
13	Diagnóstico	$VP=45, FN=5$: sensibilidad.
14	Diagnóstico	$VN=80, FP=20$: especificidad.
15	Diagnóstico	Calcula VPP con esos cuatro datos.
16	Diagnóstico	Calcula LR+.
17	Diagnóstico	Efecto de bajar umbral.
18	Diagnóstico	Interpreta $AUC=0,5$.

Banco de ejercicios: 19-36

N.º	Tema	Ejercicio
19	Lineal	Interpreta $\beta_1=2$.
20	Lineal	Predice $y=1+2x$ para $x=3$.
21	Lineal	Residuo si observado=8.
22	Lineal	Qué minimiza OLS.
23	Lineal	IC frente a intervalo de predicción.
24	Lineal	R^2 alto y causalidad.
25	Variantes	Problema que resuelve ridge.
26	Variantes	Diferencia ridge/LASSO.
27	Variantes	Por qué estandarizar.
28	Variantes	PCR frente a PLS.
29	Variantes	Qué pasa con λ enorme.
30	Variantes	Cómo elegir λ .
31	Discriminante	Papel de las probabilidades previas.
32	Discriminante	Covarianza en LDA.
33	Discriminante	Covarianza en QDA.
34	Discriminante	Forma de frontera LDA.
35	Discriminante	Por qué QDA necesita más datos.
36	Discriminante	Posterior frente a prior.

Banco de ejercicios: 37-54

N.º	Tema	Ejercicio
37	Logística	Odds para $p=0,2$.
38	Logística	p para odds= $0,25$.
39	Logística	Interpreta $\exp(\beta)=2$.
40	Logística	Por qué p queda en $[0,1]$.
41	Logística	Qué hace un umbral.
42	Logística	Por qué no duplicar probabilidad.
43	GLM	Tres piezas de GLM.
44	GLM	Media Poisson con $\eta=1$.
45	GLM	Interpreta $\exp(\beta)=0,8$.
46	GLM	Qué es un offset.
47	GLM	Supuesto media-varianza Poisson.
48	GLM	Consecuencia de sobredispersión.
49	Evaluación	Diferencia validación/test.
50	Evaluación	Detecta sobreajuste.
51	Evaluación	Accuracy engañosa.
52	Evaluación	Qué debe ir dentro de cada fold.
53	Evaluación	Menor AIC entre comparables.
54	Evaluación	Qué indica VIF alto.

Soluciones razonadas: 1-18

N.º	Corrección
1	Generar bajo una regla probabilística conocida; inventar no exige distribución.
2	Permite reproducir la misma secuencia pseudoaleatoria; no elimina azar ni garantiza validez.
3	Genera $\text{rbinom}(10000, 1, 0.5)$ y calcula la media; debe aproximarse a 0,5.
4	$2+3 \cdot 4=14$.
5	$3^2 \cdot 2=18$.
6	$\text{Var}(X)+\text{Var}(Y)+2\text{Cov}(X,Y)$.
7	$R1=20/100=0,20$; $R0=10/100=0,10$.
8	$0,20-0,10=0,10$.
9	$0,20/0,10=2$.
10	$ad/bc=(20 \cdot 90)/(80 \cdot 10)=2,25$.
11	RR:1; DR:0.
12	OR compara $p/(1-p)$; RR compara p. Aquí 2,25 frente a 2.
13	$45/(45+5)=0,90$.
14	$80/(80+20)=0,80$.
15	$45/(45+20)=0,692$.
16	$0,90/(1-0,80)=4,5$.
17	Suele subir sensibilidad y tasa de falsos positivos.
18	Discriminación equivalente aproximadamente al azar.

Soluciones razonadas: 19-36

N.º	Corrección
19	+2 unidades esperadas en Y por unidad de X, manteniendo otros X constantes.
20	$1+2\cdot3=7$.
21	$8-7=1$.
22	$\Sigma(y-\hat{y})^2$.
23	El de predicción es más ancho al incluir variabilidad individual.
24	No demuestra causalidad ni rendimiento nuevo.
25	Reduce inestabilidad/varianza encogiendo coeficientes.
26	Ridge encoge; LASSO puede anular.
27	Para que unidades no controlen la penalización.
28	PCR crea componentes sin Y; PLS usa relación con Y.
29	Coefficientes casi cero y subajuste.
30	Validación cruzada dentro de entrenamiento.
31	Reflejan frecuencia esperada de clases antes de observar x.
32	Una matriz compartida.
33	Una por clase.
34	Lineal.
35	Estima más parámetros.
36	Prior es antes de x; posterior incorpora x mediante Bayes.

Soluciones razonadas: 37-54

N.º	Corrección
37	$0,2/0,8=0,25$.
38	$0,25/1,25=0,20$.
39	Una unidad multiplica las odds por 2, ceteris paribus.
40	La inversa logit transforma cualquier real a (0,1).
41	Convierte probabilidad en decisión; cambia errores.
42	Porque el factor actúa sobre odds, no directamente sobre p.
43	Distribución, predictor lineal y enlace.
44	$\exp(1)=2,718$.
45	La tasa se multiplica por 0,8: baja 20 %.
46	Ajusta una exposición conocida con coeficiente fijo 1.
47	$\text{Var}(Y X)=E[Y X]$.
48	Errores estándar demasiado pequeños si no se corrige; revisar/usar alternativa.
49	Validación decide; test evalúa una vez al final.
50	Train muy bueno y test claramente peor.
51	Con clase rara puede ser alta prediciendo siempre la mayoritaria.
52	Todo preprocesado aprendido, selección e imputación.
53	Se prefiere el menor bajo comparabilidad y supuestos; no es verdad absoluta.
54	Inflación de varianza de coeficiente por colinealidad.

Doce modelos de verdadero/falso justificado

1. F

Afirmación: Si una simulación usa muchas repeticiones, su resultado coincide necesariamente con el valor teórico.

JUSTIFICACIÓN COMPLETA

Falso. Aumentar repeticiones reduce normalmente el error Monte Carlo, pero sigue existiendo variación aleatoria. Dos semillas pueden producir aproximaciones distintas.

2. F

Afirmación: Un odds ratio de 2 significa que el riesgo se duplica.

JUSTIFICACIÓN COMPLETA

Falso. Duplica las odds. Por ejemplo, pasar de $p=0,2$ (odds 0,25) a odds 0,5 produce $p=0,333$, no 0,4.

3. F

Afirmación: Sensibilidad y valor predictivo positivo son la misma cantidad.

JUSTIFICACIÓN COMPLETA

Falso. Sensibilidad condiona en estado real positivo; VPP condiona en test positivo y depende de la prevalencia.

4. F

Afirmación: Una AUC alta garantiza probabilidades bien calibradas.

JUSTIFICACIÓN COMPLETA

Falso. AUC mide ordenación/discriminación; un modelo puede ordenar bien y dar probabilidades sistemáticamente exageradas.

5. F

Afirmación: R^2 alto demuestra que X causa Y.

JUSTIFICACIÓN COMPLETA

Falso. Ajuste observacional no elimina confusión, causalidad inversa ni sesgos de selección.

6. V

Afirmación: El intervalo de predicción suele ser más ancho que el de confianza para la media.

JUSTIFICACIÓN COMPLETA

Verdadero. Incluye incertidumbre sobre la media y además la variabilidad de una observación nueva.

Verdadero/falso: modelos 7-12

7. F

Afirmación: LASSO y ridge anulan siempre el mismo conjunto de coeficientes.

JUSTIFICACIÓN COMPLETA

Falso. Ridge generalmente no produce ceros exactos; LASSO sí puede seleccionar variables.

8. V

Afirmación: QDA suele estimar más parámetros que LDA.

JUSTIFICACIÓN COMPLETA

Verdadero. QDA estima una matriz de covarianzas por clase; LDA comparte una.

9. F

Afirmación: $\exp(\beta)=2$ en logística duplica siempre la probabilidad.

JUSTIFICACIÓN COMPLETA

Falso. Duplica odds; el cambio en p depende de la probabilidad inicial.

10. V

Afirmación: En Poisson con enlace log, $\exp(\beta)$ es un factor multiplicativo de la media.

JUSTIFICACIÓN COMPLETA

Verdadero. $\log(\mu)$ cambia en β y por tanto μ se multiplica por $\exp(\beta)$.

11. F

Afirmación: Es correcto normalizar todo el conjunto antes de validación cruzada.

JUSTIFICACIÓN COMPLETA

Falso. La media y escala de cada fold deben aprenderse solo en su parte de entrenamiento; si no, hay fuga.

12. F

Afirmación: Una accuracy del 99 % siempre indica un gran clasificador.

JUSTIFICACIÓN COMPLETA

Falso. Con 1 % de positivos, predecir siempre negativo logra 99 % y sensibilidad 0.

Modelo de respuesta de desarrollo

Pregunta: Explique cómo construiría y evaluaría un modelo de regresión logística para predecir abandono, incluyendo interpretación y errores.

Paso	Respuesta modelo
1. Definir	$Y=1$ si abandona y 0 si no; especificar unidad de observación y predictores disponibles antes del abandono.
2. Separar	Reservar test; dentro del entrenamiento realizar validación y preprocesado sin fuga.
3. Ajustar	$\text{logit}[p(x)] = \beta_0 + \sum \beta_j x_j$ mediante máxima verosimilitud.
4. Interpretar	$\exp(\beta_j)$ es factor de odds por unidad, manteniendo otros predictores constantes; no confundir con riesgo relativo.
5. Evaluar	Log-loss/calibración para probabilidades; sensibilidad, especificidad y matriz de confusión al fijar umbral.
6. Decidir	Elegir umbral según costes de falsos positivos y negativos, no automáticamente 0,5.
7. Comprobar	Revisar colinealidad, observaciones influyentes, estabilidad y rendimiento final una vez en test.

ESTRUCTURA PARA CUALQUIER DESARROLLO

Define datos y objetivo; escribe el modelo; explica ajuste; interpreta parámetros; declara supuestos; evalúa con datos nuevos; termina con limitaciones y decisión.

Simulacro oficial de entrenamiento

Tiempo: 120 minutos. Puedes usar material escrito y calculadora programable según la guía. Entrena primero sin consultar y reserva 15 minutos para revisar justificaciones.

N.º	Tipo	Enunciado
1	V/F	La correlación cero implica independencia.
2	V/F	Si el intervalo de confianza del RR incluye 1, los datos son compatibles con ausencia de asociación al nivel usado.
3	V/F	Bajar el umbral de clasificación suele aumentar sensibilidad.
4	V/F	En regresión múltiple, β_j se interpreta manteniendo los demás predictores constantes.
5	V/F	PCR utiliza la respuesta Y para construir sus componentes.
6	V/F	Usar el test para elegir entre 20 modelos conserva una evaluación final independiente.
7	Desarrollo	Con $VP=72$, $FN=8$, $FP=30$ y $VN=190$: calcule sensibilidad, especificidad, VPP, VPN y LR+. Explique qué cambia al bajar el umbral y cómo usaría ROC sin confundir AUC con calibración.

PLANTILLA DE VERDADERO/FALSO

1) Marca V o F. 2) Define la cantidad relevante. 3) Demuestra algebraicamente o da un contraejemplo numérico. 4) Cierra relacionándolo con la afirmación exacta.

Corrección del simulacro

1. Falso

Correlación cero descarta relación lineal, no toda dependencia. Si X es simétrica alrededor de 0 y $Y=X^2$, pueden depender fuertemente y tener correlación 0.

2. Verdadero

$RR=1$ es el valor nulo. Si el intervalo incluye 1, no se descarta ese valor al nivel asociado, aunque eso no demuestra igualdad exacta.

3. Verdadero

Más observaciones superan el umbral: suelen crecer VP y FP; sensibilidad sube y especificidad puede bajar.

4. Verdadero

β_j es cambio esperado en Y por unidad de X_j , condicionando en los demás predictores del modelo.

5. Falso

PCR construye componentes desde X sin usar Y . PLS sí busca componentes relacionados con Y .

6. Falso

Cada elección adapta indirectamente el proceso al test. Hace falta validación para decidir y un test no utilizado hasta el final.

7. Desarrollo

Medida	Cálculo	Resultado
Sensibilidad	$72/(72+8)$	0,90
Especificidad	$190/(190+30)$	0,864
VPP	$72/(72+30)$	0,706
VPN	$190/(190+8)$	0,960
LR+	$0,90/(1-0,864)$	6,62

Al bajar el umbral suelen aumentar sensibilidad y falsos positivos. La ROC compara todos los umbrales mediante sensibilidad frente a 1-especificidad. AUC resume discriminación, pero no dice si las probabilidades están calibradas ni fija el mejor umbral. El umbral se escogería según costes y prevalencia del contexto.

Hoja de fórmulas y memoria

Bloque	Fórmula esencial
Riesgo	$R1=a/(a+b)$; $R0=c/(c+d)$; $DR=R1-R0$; $RR=R1/R0$; $OR=ad/bc$
Diagnóstico	$Se=VP/(VP+FN)$; $Sp=VN/(VN+FP)$; $VPP=VP/(VP+FP)$; $VPN=VN/(VN+FN)$
Likelihood ratios	$LR+=Se/(1-Sp)$; $LR-=(1-Se)/Sp$
Lineal	$y=X\beta+\epsilon$; residuo= $e=y-\hat{y}$; OLS minimiza $\sum e^2$
Logística	$odds=p/(1-p)$; $\text{logit}(p)=\log(odds)=X\beta$; $p=1/(1+e^{-\eta})$
Poisson	$\log(\mu)=X\beta$; $\exp(\beta_j)=\text{factor multiplicativo}$
Regresión métricas	$MSE=\text{media}[(y-\hat{y})^2]$; $RMSE=\sqrt{MSE}$; $MAE=\text{media} y-\hat{y} $

Colores mentales

Color	Asociación
Azul	definición y datos
Verde	interpretación correcta
Naranja	decisión o umbral
Rojo	confusión frecuente
Morado	modelo y conexión entre ideas

PREGUNTA UNIVERSAL

¿Qué estoy condicionando, qué denominador utilizo, qué datos participaron en la decisión y qué afirmación permite realmente la medida?

R: chuleta mínima

```
# Describir y simular
mean(x); sd(x); table(grupo, resultado); prop.table(tabla, 1)
rnorm(1000, mean=0, sd=1); rbinom(1000, size=1, prob=.3)

# Modelos
lm(y ~ x1 + x2, data=d)
glm(y ~ x1 + x2, family=binomial, data=d)
glm(conteo ~ x + offset(log(exposicion)), family=poisson, data=d)
MASS::lda(clase ~ x1 + x2, data=d)

# Predicción
predict(m_lineal, nuevos, interval="prediction")
predict(m_logit, nuevos, type="response")

# Reproducibilidad
set.seed(2026)
sessionInfo()
```

PARA LAS PRÁCTICAS

Lee el enunciado del campus antes de programar. Conserva código, semillas, resultados y explicación. Las prácticas oficiales deben hacerse conforme a las reglas académicas y de autoría indicadas por el equipo docente.

Errores que no debe ocultar el código

- Usar el resultado futuro como predictor.
- Normalizar con datos de prueba.
- Elegir modelo y medirlo en los mismos datos.
- Interpretar odds ratio como riesgo relativo.
- Elegir umbral sin explicar el coste de errores.
- Presentar una gráfica sin nombrar ejes, unidades y conjunto de datos.

Plan de estudio en 65 sesiones

Sesiones	Bloque	Meta
1-6	Puente	datos, probabilidad, inferencia, matrices y R
7-11	Tema 1	simulación y operaciones
12-16	Tema 2	riesgos, RR y OR
17-22	Tema 3	diagnóstico, LR y ROC
23-31	Tema 4	regresión múltiple y diagnóstico
32-37	Tema 5	regularización y componentes
38-42	Tema 6	LDA y QDA
43-49	Tema 7	logística, odds y umbral
50-54	Tema 8	GLM y Poisson
55-59	Tema 9	validación, métricas y selección
60-62	Banco	54 ejercicios y errores
63	V/F	12 justificaciones sin mirar
64	Simulacro	120 minutos
65	Corrección	reescribir respuestas incompletas

Sesión diaria de 90 minutos

Minutos	Acción
0-10	Recuperar fórmulas y vocabulario sin mirar.
10-30	Leer una explicación y rehacer su ejemplo.
30-55	Resolver cálculos o ejecutar R.
55-70	Corregir en otro color y anotar el tipo de error.
70-85	Justificar una afirmación V/F.
85-90	Escribir qué pregunta ya sabes contestar.

RITMO REALISTA

Con 3 horas diarias puedes hacer dos sesiones de 90 minutos. No avances si todavía confundes el denominador, la variable respuesta o el conjunto de datos usado para evaluar.

Glosario esencial

Término	Definición sencilla
AUC	Área bajo ROC; resume discriminación.
Calibración	Acuerdo entre probabilidades predichas y frecuencias observadas.
Clase	Categoría de la respuesta.
Covarianza	Movimiento conjunto de dos variables.
Estimador	Regla que usa la muestra para estimar un parámetro.
Generalización	Rendimiento con datos nuevos.
GLM	Modelo con distribución, predictor lineal y enlace.
Hiperparámetro	Decisión de ajuste elegida mediante validación.
Logit	Logaritmo de las odds.
Multicolinealidad	Relación lineal fuerte entre predictores.
Odds	$p/(1-p)$.
Parámetro	Cantidad desconocida de la población o modelo.
Predictor	Variable usada para explicar o predecir.
Prevalencia	Frecuencia del resultado positivo.
Regularización	Penalización que controla complejidad.
Residuo	Observado menos predicho.
Respuesta	Variable que se modeliza.
ROC	Sensibilidad frente a 1-especificidad al variar umbral.
Sobreajuste	Memorizar particularidades que no generalizan.
Umbral	Regla que convierte probabilidad en clase.
VIF	Inflación de varianza por colinealidad.

Fuente y alcance

- Guía de estudio pública UNED 2026/27 de Fundamentos de Modelado Estadístico de Datos, código 71032021, para temario, requisitos y evaluación.
- Explicaciones, ejemplos, ejercicios, código y simulacro de elaboración didáctica original para estudio.
- La guía indica el manual del curso virtual y capítulos seleccionados de An Introduction to Statistical Learning, versión R, como materiales básicos. Esos materiales prevalecen en caso de diferencia.

PRIMERA META

Hoy estudia únicamente: filas y columnas, respuesta y predictor, población y muestra, media y varianza. Después responderás cinco preguntas conmigo sin memorizar definiciones vacías.

Modelar no es adivinar: es declarar una regla, medir su incertidumbre y comprobar dónde deja de funcionar.